

# Metody Probabilistyczne - Skrypt

Wiedza skondensowana jak mleko w tubce

prof. dr hab. inż. Aleksander Lasecki

## Spis treści

<b>1</b>	<b>Podstawowe zagadnienia</b>	<b>3</b>
1.1	Podstawowe pojęcia . . . . .	3
1.2	Najmniejsze (bo małe ciała są fajne) przeliczalnie addytywne ciało zdarzeń . . . . .	3
1.3	Definicja rozkładu prawdopodobieństwa . . . . .	3
1.4	Podstawowe własności rozkładu prawdopodobieństwa . . . . .	3
1.5	Ciekawsze własności rozkładu prawdopodobieństwa . . . . .	4
1.6	Dystrybuanta . . . . .	4
<b>2</b>	<b>Prawdopodobieństwo warunkowe. Niezależność zdarzeń</b>	<b>4</b>
2.1	Prawdopodobieństwo warunkowe . . . . .	4
2.2	Niezależność zdarzeń . . . . .	4
2.3	Rodziny zdarzeń niezależnych . . . . .	5
<b>3</b>	<b>Prawdopodobieństwo zupełne. Wzór Bayesa</b>	<b>5</b>
3.1	Twierdzenie o prawdopodobieństwie całkowitym . . . . .	5
3.2	Twierdzenie Bayesa . . . . .	5
<b>4</b>	<b>Zmienne losowe</b>	<b>5</b>
4.1	Definicja zmiennej losowej . . . . .	5
4.2	Definicja rozkładu prawdopodobieństwa zmiennej losowej . . . . .	5
<b>5</b>	<b>Podstawowe typy zmiennych losowych</b>	<b>6</b>
5.1	Zmienne losowe typu skokowego . . . . .	6
5.2	Zmienne losowe typu ciągłego . . . . .	6
<b>6</b>	<b>Funkcje zmiennej losowej</b>	<b>6</b>
6.1	Definicja . . . . .	6
6.2	Własności . . . . .	7
<b>7</b>	<b>Wartość przeciętna i wariancja</b>	<b>7</b>
7.1	Definicja wartości przeciętnej . . . . .	7
7.2	Wartość przeciętna funkcji zmiennej losowej . . . . .	7
7.3	Własności wartości przeciętnej . . . . .	8
7.4	Definicja wariancji . . . . .	8
7.5	Własności wariancji . . . . .	8
7.6	Nierówność Czebyszewa . . . . .	8
7.7	Nierówność Czebyszewa-Bienayme . . . . .	8

7.8	Nierówność Markowa . . . . .	8
7.9	Centralne twierdzenie graniczne . . . . .	9
<b>8</b>	<b>Popularne rozkłady prawdopodobieństwa zmiennych losowych</b>	<b>9</b>
8.1	Rozkłady jednopunktowy i dwupunktowy . . . . .	9
8.2	Rozkład dwumianowy . . . . .	9
8.3	Rozkład Poissona(nie czytać Pojzona) . . . . .	9
8.4	Rozkład jednostajny . . . . .	10
8.5	Rozkład wykładniczy . . . . .	10
8.6	Rozkład normalny . . . . .	10

# 1 Podstawowe zagadnienia

## 1.1 Podstawowe pojęcia

**Zdarzeniem elementarnym** nazywamy niepodzielny wynik pewnego doświadczenia.

Zbiór wszystkich możliwych zdarzeń elementarnych (dla danego doświadczenia) nazywamy **przestrzenią zdarzeń elementarnych** i oznaczamy go przez  $\Omega$ .

**Zdarzeniem losowym** nazywamy pewien podzbiór  $\Omega$ . W przypadku, gdy przestrzeń jest co najwyżej przeliczalna, zbiorem wszystkich zdarzeń losowych jest po prostu  $\mathbb{P}(\Omega)$ , natomiast w przypadku gdy przestrzeń jest nieprzeliczalna zbiorem tym będzie rodzina  $\mathcal{S}$  o której za chwilę.

Jako, że zdarzenia są zbiorami, możemy na nich wykonywać takie same działania jak na zbiorach (*suma, iloczyn itp*).

**Zdarzeniem pewnym** jest cały zbiór  $\Omega$ .

**Zdarzeniem niemożliwym** jest zbiór  $\emptyset$ .

Zdarzenia **rozłączne** to takie, że  $A \cap B = \emptyset$ .

**Zdarzeniem przeciwnym** do zdarzenia  $A$  nazywamy zdarzenie  $A' = \Omega - A$ .

Rodzinę zdarzeń postaci  $\{A_i\}_{i=1}^n$ , której elementy są parami rozłączne oraz dla której  $\bigcup_{i=1}^n A_i = \Omega$  nazywamy **układem zupełnym**.

## 1.2 Najmniejsze (bo małe ciała są fajne) przeliczalnie addytywne ciało zdarzeń

Niech  $\Omega \subseteq \mathbb{R}^n$  oraz niech  $\mathcal{S}^*$  będzie taką rodziną podzbiorów  $\Omega$ , że  $\Omega \in \mathcal{S}^*$ ,  $(\forall A \in \mathcal{S}^*) (\Omega - A \in \mathcal{S}^*)$  oraz  $(\forall A_1, A_2, \dots \in \mathcal{S}^*) (\bigcup_{i=1}^{\infty} A_i \in \mathcal{S}^*)$ . Rodzinę taką nazywamy **przeliczalnie addytywnym ciałem zdarzeń**. Najmniejszą z tych rodzin oznaczać będziemy przez  $\mathcal{S}$ . Jest to rodzina zbiorów **borelowskich** której elementami są zdarzenia losowe.

## 1.3 Definicja rozkładu prawdopodobieństwa

Mamy zbiory  $\Omega$  oraz  $\mathcal{S}$ . Definiujemy funkcję **P** następująco:

$$\mathbf{P} : \mathcal{S} \rightarrow \mathbb{R}$$

$$(\forall A \in \mathcal{S}) (\mathbf{P}(A) \geq 0)$$

$$\mathbf{P}(\Omega) = 1$$

$$(\forall A_1, A_2, \dots \in \mathcal{S}) \left( (\forall A_i, A_j) (A_i \cap A_j = \emptyset) \rightarrow \mathbf{P} \left( \bigcup_{i=1}^{\infty} A_i \right) = \sum_{i=1}^{\infty} \mathbf{P}(A_i) \right)$$

Funkcję taką nazywamy **rozkładem prawdopodobieństwa**, a jej wartości **prawdopodobieństwem** zdarzeń losowych.

## 1.4 Podstawowe własności rozkładu prawdopodobieństwa

$$\mathbf{P}(\emptyset) = 0$$

$$\mathbf{P} \left( \bigcup_{i=1}^n A_i \right) = \sum_{i=1}^n \mathbf{P}(A_i)$$

$$\mathbf{P}(A') = 1 - \mathbf{P}(A)$$

$$\mathbf{P}(A \cup B) = \mathbf{P}(A) + \mathbf{P}(B) - \mathbf{P}(A \cap B)$$

$$A \subset B \rightarrow \mathbf{P}(A) \leq \mathbf{P}(B)$$

## 1.5 Ciekawsze własności rozkładu prawdopodobieństwa

Jeśli zdarzenia  $A_1, A_2, \dots$  stanowią ciąg **wstępujący**, czyli mamy  $A_1 \subset A_2 \subset \dots$  oraz jeśli  $\bigcup_i A_i = A$  wtedy:

$$\lim_{n \rightarrow \infty} \mathbf{P}(A_n) = \mathbf{P}(A)$$

Dowód przeprowadzamy rozpatrując różnice między kolejnymi zbiorami ( $A_i - A_{i-1} = B_i$ ).

Jeśli zdarzenia  $A_1, A_2, \dots$  stanowią ciąg **zstępujący**, czyli mamy  $A_1 \supset A_2 \supset \dots$  oraz jeśli  $\bigcap_i A_i = A$  wtedy:

$$\lim_{n \rightarrow \infty} \mathbf{P}(A_n) = \mathbf{P}(A)$$

Do dowodu wykorzystujemy poprzedni fakt.

## 1.6 Dystrybuenta

Niech  $\Omega = \mathbb{R}^1$ . Definiujemy funkcję  $\mathbf{F}$  w następujący sposób:

1.  $\mathbf{F}$  jest niemalejąca
2.  $\lim_{x \rightarrow -\infty} \mathbf{F}(x) = 0$  oraz  $\lim_{x \rightarrow \infty} \mathbf{F}(x) = 1$
3.  $\mathbf{F}$  jest lewostronnie ciągła

Taką funkcję nazywamy **dystrybuentą** i definiuje ona, jednoznacznie, rozkład prawdopodobieństwa w następujący sposób:

$$\mathbf{P}(\langle a; b \rangle) = \mathbf{F}(b) - \mathbf{F}(a)$$

Mając rozkład prawdopodobieństwa możemy również w jednoznaczny sposób wyznaczyć dystrybuentę jako:

$$\mathbf{F}(x) = \mathbf{P}((-\infty; x))$$

## 2 Prawdopodobieństwo warunkowe. Niezależność zdarzeń

### 2.1 Prawdopodobieństwo warunkowe

Prawdopodobieństwo zdarzenia  $A$  pod warunkiem wystąpienia zdarzenia  $B$  (przy założeniu, że  $\mathbf{P}(B) > 0$ ) oznaczamy przez  $\mathbf{P}(A|B)$  i definiujemy następująco:

$$\mathbf{P}(A|B) = \frac{\mathbf{P}(A \cap B)}{\mathbf{P}(B)}$$

$$\mathbf{P}(A \cap B) = \mathbf{P}(A|B) \mathbf{P}(B)$$

Zauważmy, że funkcja  $\mathbf{P}(A|B)$ , przy ustalonym  $B$  spełnia aksjomaty rozkładu prawdopodobieństwa.

Na podstawie powyższego wzoru możemy, za pomocą indukcji matematycznej, wyznaczyć wzór na prawdopodobieństwo iloczynu zbiorów:

$$\mathbf{P}(A_1 \cap A_2 \cap \dots \cap A_n) = \mathbf{P}(A_n | A_1 \cap A_2 \cap \dots \cap A_{n-1}) \dots \mathbf{P}(A_3 | A_1 \cap A_2) \mathbf{P}(A_2 | A_1) \mathbf{P}(A_1)$$

### 2.2 Niezależność zdarzeń

Zdarzenie nazywamy **niezależnymi** jeśli zachodzi następujący warunek:

$$\mathbf{P}(A|B) = \mathbf{P}(A)$$

$$\mathbf{P}(B|A) = \mathbf{P}(B)$$

Warunek ten możemy również zapisać w postaci:

$$\mathbf{P}(A \cap B) = \mathbf{P}(A) \mathbf{P}(B)$$

## 2.3 Rodziny zdarzeń niezależnych

Rodzinę zdarzeń  $\{A_i\}_{i=1}^n$  nazywamy rodziną zdarzeń niezależnych jeśli dla każdych  $k_1, k_2, \dots, k_p$ , takich, że  $1 \leq k_1 \leq \dots \leq n$  mamy:

$$\mathbf{P}(A_{k_1} \cap A_{k_2} \cap \dots \cap A_{k_p}) = \mathbf{P}(A_{k_1}) \mathbf{P}(A_{k_2}) \dots \mathbf{P}(A_{k_p})$$

Rodzinę zdarzeń  $\{A_i\}_{i=1}^\infty$  nazywamy rodziną zdarzeń niezależnych jeśli dla każdego  $n \in \mathbb{N}$ , takiego, że  $n > 1$  rodzina  $\{A_i\}_{i=1}^n$  jest rodziną zdarzeń niezależnych.

Niech  $\{A_i\}_{i=1}^{n+1}$  będzie rodziną zdarzeń niezależnych. Wtedy zdarzenia  $\bigcup_{i=1}^n A_i$  oraz  $A_{n+1}$  są parą zdarzeń niezależnych.

Niech  $\{A_i\}_{i=1}^n$  będzie rodziną zdarzeń niezależnych. Wtedy  $\{A'_i\}_{i=1}^n$ , czyli rodzina składająca się ze zdarzeń  $A'_1, A'_2$  itd, jest rodziną zdarzeń niezależnych.

## 3 Prawdopodobieństwo zupełne. Wzór Bayesa

### 3.1 Twierdzenie o prawdopodobieństwie całkowitym

Niech  $\mathcal{A} = \{A_i\}_i$  będzie układem zupełnym takim, że  $(\forall C \in \mathcal{A}) (\mathbf{P}(C) > 0)$ . Wtedy zachodzi następujący wzór:

$$\mathbf{P}(B) = \sum_i \mathbf{P}(B|A_i) \mathbf{P}(A_i)$$

### 3.2 Twierdzenie Bayesa

Niech  $\mathcal{A} = \{A_i\}_i$  będzie układem zupełnym takim, że  $(\forall C \in \mathcal{A}) (\mathbf{P}(C) > 0)$  oraz  $\mathbf{P}(B) > 0$ . Wtedy prawdziwe jest następujące zdanie:

$$(\forall C \in \mathcal{A}) \left( \mathbf{P}(C|B) = \frac{\mathbf{P}(B|C) \mathbf{P}(C)}{\sum_i \mathbf{P}(B|A_i) \mathbf{P}(A_i)} \right)$$

Lub inaczej:

$$(\forall C \in \mathcal{A}) \left( \mathbf{P}(C|B) = \frac{\mathbf{P}(B|C) \mathbf{P}(C)}{\mathbf{P}(B)} \right)$$

## 4 Zmienne losowe

### 4.1 Definicja zmiennej losowej

Niech  $(\Omega, \mathbf{S}, \mathbf{P})$  będzie dowolną przestrzenią probabilistyczną. Zmienną losową  $X$  nazywamy funkcję zdefiniowaną następująco:

$$X : \Omega \rightarrow \mathbb{R}$$

$$(\forall x \in \mathbb{R}) (\{\omega \in \Omega : X(\omega) < x\} \in \mathbf{S})$$

W szczególności, gdy  $\Omega$  jest zbiorem co najwyżej przeliczalnym, każde przekształcenie typu  $X : \Omega \rightarrow \mathbb{R}$  jest zmienną losową.

### 4.2 Definicja rozkładu prawdopodobieństwa zmiennej losowej

Rozkładem prawdopodobieństwa zmiennej losowej  $X$  na przestrzeni probabilistycznej  $(\Omega, \mathbf{S}, \mathbf{P})$  jest następująca funkcja, określona na rodzinie zbiorów borelowskich na prostej (oznaczymy ją przez  $\mathbf{S}_B$ ):

$$\mathbf{P}_X(A) = \mathbf{P}(\{\omega \in \Omega : X(\omega) \in A\})$$

Zauważmy, że zdefiniowane wyżej byty indukują nową przestrzeń probabilistyczną  $(\mathbb{R}, \mathbf{S}_B, \mathbf{P}_X)$ .

Zgodnie z metodą podaną wcześniej, dystrybuentę rozkładu prawdopodobieństwa zmiennej losowej  $X$  definiujemy jako:

$$\mathbf{F}_X(x) = \mathbf{P}_X((-\infty; x))$$

Otrzymujemy również następującą zależność:

$$\mathbf{P}_X((a, b)) = \mathbf{P}(\{\omega \in \Omega : a \leq X(\omega) < b\}) = \mathbf{F}_X(b) - \mathbf{F}_X(a)$$

Możemy również stosować skrócony zapis:

$$\mathbf{P}(a \leq X < b) = \mathbf{P}(\{\omega \in \Omega : a \leq X(\omega) < b\})$$

## 5 Podstawowe typy zmiennych losowych

### 5.1 Zmienne losowe typu skokowego

Zmienna losowa typu skokowego (bądź inaczej: dyskretna zmienna losowa) to taka dla której istnieje co najwyżej przeliczalny zbiór  $\mathcal{X}$  (czyli zbiór postaci  $\{x_1, \dots, x_n\}$  lub  $\{x_1, x_2, \dots\}$ , gdzie  $x_k$  nazywamy wartościami zmiennej losowej) dla którego  $\mathbf{P}_X(\mathcal{X}) = 1$ .

Rozkład prawdopodobieństwa zmiennej losowej wygląda wtedy następująco:

$$p(x_k) = \mathbf{P}(\{\omega \in \Omega : X(\omega) = x_k\})$$

Zauważmy, że  $\sum_k p(x_k) = 1$  oraz, że dystrybuenta naszej zmiennej losowej jest lewostronnie ciągła, przedziałami stała i ma skoki w punktach gdzie  $p(x_k) > 0$  o wartości  $p(x_k)$ .

### 5.2 Zmienne losowe typu ciągłego

Niech teraz  $\mathcal{X} = \mathcal{R}$ . Zmienną losową typu ciągłego jest funkcja zdefiniowana w następujący sposób:

$$\mathbf{F}(x) = \int_{-\infty}^x f(u) du$$

Gdzie  $f$  jest funkcją nazywaną **gęstością prawdopodobieństwa**, która jest nieujemna oraz spełnia:

$$\int_{-\infty}^{\infty} f(u) du = 1$$

W przedziałach w których  $f$  jest ciągła zachodzi zależność:

$$\mathbf{F}'(x) = f(x)$$

Prawdopodobieństwo  $\mathbf{P}(x_1 \leq X < x_2)$  dla  $x_1 < x_2$  określamy, z własności dystrybuenty, jako:

$$\mathbf{P}(x_1 \leq X < x_2) = \int_{x_1}^{x_2} f(u) du$$

Zauważmy również, że dla dowolnej liczby rzeczywistej  $x_0 \in \mathbb{R}$  mamy:

$$\mathbf{P}(X = x_0) = 0$$

## 6 Funkcje zmiennej losowej

### 6.1 Definicja

Niech  $X$  będzie zmienną losową oraz niech  $g$  będzie dowolną funkcją borelowską. Wtedy **funkcję zmiennej losowej**  $Y$  definiujemy jako:

$$Y(\omega) = g(X(\omega))$$

## 6.2 Własności

Jeżeli znamy gęstość zmiennej losowej  $X$ , dystrybuantę zmiennej losowej  $Y$  znajdujemy w następujący sposób:

$$\mathbf{F}_Y(y) = \mathbf{P}(Y < y) = \mathbf{P}(g(X) < y) = \int_{\{x: g(x) < y\}} f_X(x) dx$$

Jeśli  $g$  jest funkcją różniczkowalną oraz ściśle monotoniczną (czyli rosnącą lub malejącą), oznaczamy przez  $g^{-1}$  funkcję odwrotną do  $g$  i mamy: Dla  $g$  rosnącej:

$$\frac{d}{dy} \mathbf{F}_Y(y) = f_Y(Y) = \frac{d}{dy} \int_{\{x: g(x) < y\}} f_X(x) dx = \frac{d}{dy} \int_{\{x: x < g^{-1}(y)\}} f_X(x) dx = f_X(g^{-1}(y)) (g^{-1})'(y)$$

Dla  $g$  malejącej:

$$\frac{d}{dy} \mathbf{F}_Y(y) = f_Y(Y) = \frac{d}{dy} \int_{\{x: g(x) < y\}} f_X(x) dx = \frac{d}{dy} \int_{\{x: x > g^{-1}(y)\}} f_X(x) dx = -f_X(g^{-1}(y)) (g^{-1})'(y)$$

Czyli ogólnie:

$$\frac{d}{dy} \mathbf{F}_Y(y) = f_X(g^{-1}(y)) |(g^{-1})'(y)|$$

Pamiętajmy, że gdy  $X$  jest typu ciągłego oraz  $g$  jest ściśle monotoniczna nie implikują tego, że  $Y$  jest typu ciągłego.

## 7 Wartość przeciętna i wariancja

### 7.1 Definicja wartości przeciętniej

Wartość przeciętną/oczekiwaną/średnią dla zmiennej losowej  $X$  typu skokowego określamy jako:

$$\mathbb{E}(X) = \sum_k x_k p(x_k)$$

Przy warunku, że szereg  $\sum_k |x_k| p(x_k)$  jest zbieżny.

Wartość przeciętną/oczekiwaną/średnią dla zmiennej losowej  $X$  typu ciągłego określamy jako:

$$\mathbb{E}(X) = \int_{\mathbb{R}} x f(x) dx$$

Przy warunku, że całka  $\int_{\mathbb{R}} |x| f(x) dx$  jest zbieżna.

### 7.2 Wartość przeciętna funkcji zmiennej losowej

Niech zmienna losowa  $Y$  będzie funkcją zmiennej losowej  $X$  ( $Y = g(X)$ ), przy czym znamy rozkład prawdopodobieństwa zmiennej losowej  $X$ .

Wartość przeciętną/oczekiwaną/średnią dla zmiennej losowej  $Y$  typu skokowego określamy jako:

$$\mathbb{E}(Y) = \sum_k g(x_k) p(x_k)$$

Przy warunku, że szereg  $\sum_k |g(x_k)| p(x_k)$  jest zbieżny.

Wartość przeciętną/oczekiwaną/średnią dla zmiennej losowej  $Y$  typu ciągłego określamy jako:

$$\mathbb{E}(Y) = \int_{\mathbb{R}} g(x) f(x) dx$$

Przy warunku, że całka  $\int_{\mathbb{R}} |g(x)| f(x) dx$  jest zbieżna.

### 7.3 Własności wartości przeciętnej

Niech zmienna losowa  $Y$  będzie funkcją zmiennej losowej  $X$  ( $Y = g(X)$ ) oraz niech  $g$  będzie postaci  $aX + b$  dla dowolnych  $a, b$ . Wtedy określamy wartość przeciętną jako:

$$\mathbb{E}(Y) = \mathbb{E}(aX + b) = a\mathbb{E}(X) + b$$

Niech zmienna losowa  $Y$  będzie funkcją zmiennej losowej  $X$  ( $Y = \sum_i g_i(X)$ ) oraz niech  $\mathbb{E}(g_i(X))$  istnieje dla każdego  $i \in [N]$ . Wtedy określamy wartość przeciętną jako:

$$\mathbb{E}(Y) = \mathbb{E}\left(\sum_i g_i(X)\right) = \sum_i \mathbb{E}(g_i(X))$$

### 7.4 Definicja wariancji

Wariancja opisuje 'rozrzut' wartości zmiennej losowej względem wartości oczekiwanej. Definiujemy ją w następujący sposób:

$$\mathbb{V}(X) = \mathbb{E}((X - \mathbb{E}(X))^2)$$

Lub inaczej:

$$\mathbb{V}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2$$

Zmienną losową  $X$  dla której  $\mathbb{E}(X) = 0$ ,  $\mathbb{V}(X) = 1$  nazywamy **zmienną losową standaryzowaną**. Pierwiastek z wariancji nazywamy **odchyleniem standardowym**.

### 7.5 Własności wariancji

Niech  $X$  będzie zmienną losową dla której istnieje wariancja. Wtedy zachodzi zależność:

$$\mathbb{V}(aX + b) = a^2\mathbb{V}(X)$$

Warunkiem koniecznym i dostatecznym tego, aby  $\mathbb{V}(X) = 0$  jest to, aby rozkład  $X$  był jednopunktowy. Funkcja  $\varphi$  określona jako:

$$\varphi(c) = \mathbb{E}((X - c)^2)$$

Przyjmuje najmniejszą wartość gdy  $c = \mathbb{E}(X)$ .

### 7.6 Nierówność Czebyszewa

Jeśli zmienna losowa  $X$  spełniająca warunek  $\mathbf{P}(X < 0) = 0$  ma wartość przeciętną  $\mathbb{E}(X)$ , to dla dowolnego  $\varepsilon > 0$  mamy:

$$\mathbf{P}(X \geq \varepsilon) \leq \frac{\mathbb{E}(X)}{\varepsilon}$$

### 7.7 Nierówność Czebyszewa-Bienayme

Jeśli zmienna losowa  $X$  ma wariancję  $\mathbb{V}(X)$  i wartość przeciętną  $\mathbb{E}(X)$ , to dla dowolnego  $\varepsilon > 0$  mamy:

$$\mathbf{P}(|X - \mathbb{E}(X)| \geq \varepsilon) \leq \frac{\mathbb{V}(X)}{\varepsilon^2}$$

### 7.8 Nierówność Markowa

Jeśli zmienna losowa  $X$  ma wartość przeciętną  $\mathbb{E}(X)$ , to dla dowolnych  $\varepsilon, p > 0$  mamy:

$$\mathbf{P}(|X| \geq \varepsilon) \leq \frac{\mathbb{E}(|X|^p)}{\varepsilon^p}$$



## 7.9 Centralne twierdzenie graniczne

Dla danego rozkładu, określonej wartości oczekiwanej  $m$  i skończonej wariancji  $\sigma^2$  określamy zbiór zdarzeń niezależnych, które oznaczamy przez  $X_i$ . Wtedy:

$$\frac{\frac{1}{n} \sum_{i=1}^n X_i - m}{\frac{\sigma}{\sqrt{n}}}$$

Zbiega według rozkładu do standardowego rozkładu normalnego przy  $n \rightarrow \infty$ .

## 8 Popularne rozkłady prawdopodobieństwa zmiennych losowych

### 8.1 Rozkłady jednopunktowy i dwupunktowy

Niech  $\mathcal{X} = \{x_0\}$  oraz  $\mathbf{P}(X = x_0) = 1$ . Wtedy mówimy, że zmienna losowa  $X$  ma **rozkład jednopunktowy**.  $\mathbb{E}(X) = x_0$ ,  $\mathbb{V}(X) = 0$ .

Niech  $\mathcal{X} = \{x_0, x_1\}$  oraz  $\mathbf{P}(X = x_0) = p$ ,  $\mathbf{P}(X = x_1) = 1 - p$ . Wtedy mówimy, że zmienna losowa  $X$  ma **rozkład dwupunktowy**.  $\mathbb{E}(X) = p(x_0 - x_1) + x_1$ ,  $\mathbb{V}(X) = p(1 - p)(x_0 - x_1)^2$ .

### 8.2 Rozkład dwumianowy

Wykonujemy  $n$  razy doświadczenie, które można opisać za pomocą rozkładu dwumianowego, przy czym możliwe wyniki to  $A$  oraz  $A'$ . Prawdopodobieństwo wystąpienia  $k$  sukcesów wyraża się wzorem:

$$\mathbf{P}(X = k) = \binom{n}{k} p^k q^{n-k}$$

Zauważmy, że:

$$\sum_{k=0}^n \binom{n}{k} p^k q^{n-k} = 1$$
$$\mathbb{E}(X) = np, \quad \mathbb{V}(X) = np(1 - p)$$

Wartość najbardziej prawdopodobną (nie mylić z wartością oczekiwaną) określamy jako:

$$\left[ (n+1)p \right]$$

Gdzie  $[x]$  oznacza część całkowitą z  $x$ .

### 8.3 Rozkład Poissona (nie czytać Pojzona)

Niech  $\mathcal{X} = \mathbb{N}$  oraz niech  $k \in \mathbb{N}$ . Rozkład Poissona ( $\mathbf{Pois}(\lambda)$ ), gdzie  $\lambda > 0$ ) określamy jako:

$$\mathbf{P}(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

Mamy, również:

$$\mathbb{E}(X) = \mathbb{V}(X) = \lambda$$

Zauważmy, że jeśli rozważamy serię doświadczeń zgodną ze schematem Bernoulliego, gdzie liczba doświadczeń jest duża, a prawdopodobieństwo sukcesu małe, rozkład Poissona jest dobrą aproksymacją rozkładu Bernoulliego (dwumianowego) dla  $\lambda = np$ .

## 8.4 Rozkład jednostajny

$$f(x) = \begin{cases} 0 & : x \leq a \\ \frac{1}{b-a} & : a < x \leq b \\ 0 & : x > b \end{cases}$$

$$F(x) = \begin{cases} 0 & : x \leq a \\ \frac{x-a}{b-a} & : a < x \leq b \\ 0 & : x > b \end{cases}$$

$$\mathbb{E}(X) = \frac{a+b}{2} \quad \mathbb{E}(X^2) = \frac{a^2 + ab + b^2}{3} \quad \mathbb{V}(X) = \frac{(b-a)^2}{12}$$

## 8.5 Rozkład wykładniczy

$$f(x) = \begin{cases} 0 & : x < 0 \\ \lambda e^{-\lambda x} & : x \geq 0, \lambda > 0 \end{cases}$$

$$F(x) = \begin{cases} 0 & : x < 0 \\ 1 - e^{-\lambda x} & : x \geq 0, \lambda > 0 \end{cases}$$

$$\mathbb{E}(X) = \frac{1}{\lambda} \quad \mathbb{V}(X) = \frac{1}{\lambda^2}$$

## 8.6 Rozkład normalny

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-m)^2}{2\sigma^2}}$$

$$F(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-m)^2}{2\sigma^2}}$$

$$\mathbb{E}(X) = m \quad \mathbb{V}(X) = \sigma^2$$